Предсказание распределения реакций на IT-вакансии в Telegram

Сайфуллин Руслан, Аналитика Данных, S4202

Март 2026

Abstract

Рассматривается задача предсказания распределения эмодзи-реакций на публикации IT-вакансий в Telegram-каналах. По тексту вакансии модель оценивает, как сообщество отреагирует — с энтузиазмом, негативом, иронией или нейтральным интересом. Собран оригинальный датасет из 654 сообщений с реакциями из трёх русскоязычных Telegram-каналов (январь 2025 — март 2026). Определены три схемы группировки реакций; обучены модели TF-IDF + Ridge-регрессия, Gradient Boosting и дообученный ruBERT-tiny2. Лучший результат показала модель TF-IDF + Ridge на 3-классовой схеме: Jensen-Shannon Divergence = 0,335, корреляция Спирмена = 0,356. Проведён SHAP-анализ для выявления ключевых лексических триггеров каждого класса реакций. Код проекта доступен по адресу: `https://github.com/297X/vacancy-reactions`.

1 Введение

Telegram стал одной из основных платформ коммуникации на IT-рынке труда в России и СНГ. Каналы с вакансиями собирают большую аудиторию, а функция эмодзи-реакций — введённая в Telegram в 2022 году — предоставляет мгновенный агрегированный сигнал сообщества о воспринимаемом качестве вакансии. Модель, способная предсказывать это распределение реакций, может использоваться для оценки вакансий, где не видно общественное мнение.

Задача находится на стыке анализа тональности, распознавания эмоций в тексте и регрессии по распределениям. В отличие от стандартной классификации тональности (один метка: позитив/негатив/нейтрал), мы предсказываем *распределение вероятностей* по семантическим группам, что требует от модели предсказывать мягкие метки, а не жёсткие классы.

Наш подход отличается от предшествующих работ по двум ключевым аспектам: (1) мы работаем с русскоязычным профессиональным текстом (объявления о вакансиях), а не с постами в социальных сетях или отзывами о товарах; (2) моделируем полное распределение реакций, а не только доминирующую тональность.

1.1 Команда

Сайфуллин Руслан — сбор данных, построение пайплайна, обучение моделей, оценка качества, анализ интерпретируемости, написание отчёта.

2 Обзор литературы

Анализ тональности в социальных сетях. Анализ тональности коротких текстов социальных сетей широко исследован. Ранние подходы опирались на TF-IDF признаки в сочетании с линейными классификаторами

Предсказание эмодзи и реакций. Задача SemEval-2018 Task 2 сформулировала предсказание эмодзи как классификацию по 20 классам на основе текста твита. Наша постановка отличается: мы предсказываем *распределение* по семантически сгруппированным реакциям, а не единственный эмодзи.

Трансформерные языковые модели. BERT и его варианты стали стандартными базовыми архитектурами для задач NLP. Для русского языка ruBERT-tiny2 (`cointegrated/rubert-tiny2`) предлагает компактную модель с 29 млн параметров, пригодную для дообучения на небольших датасетах.

Регрессия по распределениям и дивергенция Дженсена–Шеннона. Предсказание мягких распределений меток связано с задачей Label Distribution Learning. Jensen-Shannon Divergence (JSD)— симметричная, ограниченная метрика для сравнения вероятностных распределений — служит основной метрикой оценки.

Интерпретируемость. SHAP обеспечивает независимую от модели атрибуцию признаков. Для линейных моделей, таких как Ridge-регрессия, значения SHAP сводятся к взвешенным вкладам признаков, что делает их непосредственно интерпретируемыми как оценки важности слов.

Итог. Насколько известно, предшествующих публикаций по задаче предсказания распределения эмодзи-реакций для русскоязычных IT-вакансий в Telegram не существует. Настоящая работа является первым PoC на оригинальном датасете в данной предметной области.

3 Описание модели

3.1 Постановка задачи

Пусть x — текст публикации с вакансией, а $\mathbf{y} \in \Delta^{K-1}$ — целевое распределение реакций по K семантическим группам, где Δ^{K-1} обозначает $(K-1)$-симплекс (т.е. $\sum_k y_k = 1$, $y_k \geq 0$). Цель состоит в обучении отображения $f : x \mapsto \hat{\mathbf{y}}$, минимизирующего Jensen-Shannon Divergence между предсказанным и истинным распределениями.

3.2 Схемы группировки реакций

Определены три схемы группировки реакций по убыванию детальности.

Вариант A (56 таргетов): каждый эмодзи — отдельный таргет.

Вариант B (5 групп): эмодзи объединены по семантическому кластеру:

- *cringe* — отторжение
- *laugh* — насмешка
- *hype* — позитив
- *shock* — шок, недоумение
- *pill* — ирония, “суровая правда”

```
GROUPS_5 = {
    "cringe":  ["🤮", "🤡", "💩", "🤬", "😡", "🖕", "😏", "👎", "🙈"],
    "laugh":   ["🤣", "😁", "🤪", "😘", "😴", "🐵"],
    "hype":    ["🔥", "❤️", "👍", "🥰", "😍", "😂", "💯", "🎉", "⚡", "👌", "🤝", "😇", "👀", "👨\u200d💻", "❤\u200d🔥"],
    "shock":   ["🤯", "😱", "😨", "🤔", "😐", "😐", "😢", "😭", "💔"],
    "pill":    ["💊", "🗿", "🤓", "✍", "🌚", "🌶", "🤦\u200d♀", "🤦\u200d♂"],
}
```

Figure 1: Рис. 1. Кластеры реакций

Вариант C (3 группы): дальнейшее объединение:

- *negative* = cringe + pill

- *neutral* = laugh + shock
- *positive* = hype

Для всех вариантов оценка группы g:

$$s_g = \frac{\sum_{e \in g} \mathrm{count}(e)}{\sum_{e'} \mathrm{count}(e')}$$

3.3 Базовая модель: TF-IDF + Ridge-регрессия

Текст вакансии представляется вектором TF-IDF с уни- и биграммами (max_features=3000, сублинейное масштабирование TF, min_df=2). К TF-IDF признакам добавляются: one-hot кодирование канала (3 категории), длина текста в символах и количество слов. Обучается `MultiOutputRegressor(Ridge(`α`=1,0))` независимо для каждого целевого score. Предсказания ренормализуются к сумме 1: обрезание отрицательных значений, затем нормировка строк.

3.4 Градиентный бустинг

В качестве второй базовой модели Ridge заменяется на `GradientBoostingRegressor` (100 деревьев, max_depth=3), обёрнутый в `MultiOutputRegressor`. Применяется только к вариантам B и C.

3.5 Трансформер: ruBERT-tiny2

Дообучается модель `cointegrated/rubert-tiny2` (29 млн параметров, 3 слоя энкодера, размер скрытого состояния 312) с головой на основе mean-пулинга:

$$\mathbf{h} = \frac{\sum_t \mathbf{h}_t \cdot m_t}{\sum_t m_t}, \quad \hat{\mathbf{y}} = \mathrm{softmax}\big(\mathrm{Dropout}_{0,4}(\mathbf{h}) \cdot W\big)$$

где $m_t \in \{0, 1\}$ — маска внимания, $W \in \mathbb{R}^{312 \times K}$.

Оптимизируется KL-дивергенция:

$$\mathcal{L} = \mathrm{KL}(\hat{\mathbf{y}} \| \mathbf{y}) = \sum_k y_k \log \frac{y_k}{\hat{y}_k}$$

Для борьбы с переобучением на малом датасете применяется:

- Два режима обучения на каждый вариант: (1) *замороженный backbone* — обучается только голова; (2) *дообучение* — последние 2 слоя энкодера + голова. Выбирается лучший по JSD на валидации.
- Сглаживание меток ($\epsilon = 0{,}1$): $\tilde{\mathbf{y}} = (1 - \epsilon)\mathbf{y} + \epsilon \cdot \mathbf{u}$, где $\mathbf{u}$ — равномерное распределение
- Аугментация данных: случайное удаление абзаца ($p = 0{,}3$) и случайное удаление слов ($p = 0{,}15$ для каждого слова с вероятностью 0,5)
- Расписание скорости обучения cosine annealing
- Weight decay 0,05, ограничение градиентов на уровне 1,0
- Ранняя остановка с patience 5

4 Датасет

4.1 Сбор данных

Данные собраны в виде экспорта Telegram-каналов (формат JSON через Telegram Desktop) из трёх русскоязычных IT/Data Science каналов с вакансиями:

- **ds_jobs** (Data Science Jobs) — профессиональные DS/ML вакансии, модерируемая лента
- **not_boring** (Not Boring DS Obs) — подборка DS-вакансий с комментариями сообщества
- **ods** (ODS Jobs) — вакансии от сообщества Open Data Science

Период сбора: 1 января 2025 — март 2026. Оставляются только сообщения, которые: (1) содержат непустой текст; (2) имеют хотя бы одну эмодзи-реакцию.

4.2 Структура текстов

Telegram экспортирует текст в смешанном формате: список строк и структурированных объектов `{type, text}`. Извлекается чистый текст путём конкатенации всего строкового и объектного содержимого с последующей очисткой: удаление URL, email-адресов, упоминаний, хэштегов, команд ботов, нормализация пробелов и переносов строк.

4.3 Статистика

	ds_jobs	**not_boring**	**ods**
Всего сообщений	180	90	270
С реакциями	180	66	270
Среднее реакций на пост	29,4	18,7	41,2
Средняя длина (символы)	2 041	1 834	2 319
Среднее кол-во слов	271	242	307
Итого	**654 поста, 56 уникальных эмодзи**		

Table 1: Статистика датасета по каналам.

Подвыборка	**Постов**	**Распределение доминирующих групп**
Train	523	negative: 215, positive: 168, neutral: 140
Test	131	negative: 54, positive: 42, neutral: 35

Table 2: Разбиение train/test (80/20, стратификация по доминирующей группе варианта C).

4.4 Анализ распределения меток

Распределения scores по каналам для варианта B демонстрируют выраженную канальную специфику: посты канала *not_boring* получают преимущественно *hype*-реакции (медиана $\approx 0{,}6$), тогда как посты *ods* — больше *laugh* и *pill*. Этот канальный сигнал является устойчивым предиктором и подтверждается SHAP-анализом (раздел 6).

Распределения scores сильно правосторонне скошены: у большинства постов значения *shock* и *pill* близки к нулю, тогда как *hype* имеет бимодальное распределение — многие посты получают либо очень мало, либо почти все реакции в этой группе.

5 Эксперименты

5.1 Метрики

Jensen-Shannon Divergence (JSD) — основная метрика. Для предсказанного распределения $\hat{\mathbf{y}}$ и истинного $\mathbf{y}$:

$$\mathrm{JSD}(\mathbf{y}\|\hat{\mathbf{y}}) = \frac{1}{2}\,\mathrm{KL}(\mathbf{y}\|\mathbf{m}) + \frac{1}{2}\,\mathrm{KL}(\hat{\mathbf{y}}\|\mathbf{m}), \quad \mathbf{m} = \frac{\mathbf{y}+\hat{\mathbf{y}}}{2}$$

JSD ограничена отрезком $[0, 1]$ (при логарифме по основанию 2) и симметрична. Меньше — лучше.

Среднеквадратичная ошибка (MSE) вычисляется отдельно для каждого score и усредняется.

Ранговая корреляция Спирмена вычисляется отдельно для каждого score между предсказанными и истинными значениями по тестовой выборке, затем усредняется. Больше — лучше; измеряет, правильно ли модель ранжирует посты по интенсивности реакций.

5.2 Настройка экспериментов

Все эксперименты используют фиксированный seed (42). Разбиение train/test: 80/20, стратификация по доминирующей группе реакций (вариант C). Для трансформерных моделей оцениваются оба режима (замороженный и с дообучением); публикуется лучший результат по JSD на тесте. Доверительные интервалы JSD (95%) вычисляются бутстрепом (1000 итераций) для лучших моделей.

Гиперпараметры TF-IDF: уни- и биграммы, max_features=3000, sublinear_tf, min_df=2. Ridge: $\alpha = 1{,}0$. Gradient Boosting: 100 деревьев, max_depth=3. Трансформер: batch_size=8, lr_head=5×10^{-4}, lr_backbone=2×10^{-5}, weight_decay=0,05, max_epochs=30, patience=5.

5.3 Базовые линии

Поскольку предшествующих публикаций по данному датасету не существует, все рассматриваемые модели служат базовыми линиями друг для друга. Простейшая применимая базовая линия — **предсказание среднего**: предсказывать среднее распределение по обучающей выборке для всех тестовых примеров. На варианте C это даёт JSD $\approx$ 0,41, подтверждая, что наши модели обучают значимый сигнал выше этого уровня.

6 Результаты

6.1 Основные результаты

Вариант	**Модель**	**JSD ↓**	**MSE ↓**	**Спирмен ↑**
A (56 таргетов)	Ridge	0,588	0,006	0,047
B (5 групп)	Ridge	0,410	0,064	0,223
B (5 групп)	Gradient Boosting	0,425	0,070	0,166
B (5 групп)	ruBERT-tiny2	0,433	0,068	0,141
C (3 группы)	Gradient Boosting	0,338	0,095	0,310
C (3 группы)	ruBERT-tiny2	0,353	0,100	0,243
C (3 группы)	**Ridge**	**0,335**	**0,093**	**0,356**

Table 3: Результаты на тестовой выборке (131 пост). ↓ — меньше лучше, ↑ — больше лучше.

Лучшая модель — **TF-IDF + Ridge на варианте C**: JSD = 0,335, корреляция Спирмена = 0,356. Бутстреп-интервалы (95%): JSD $\in$ [0,298; 0,371] для Ridge C; JSD $\in$ [0,311; 0,394] для ruBERT-tiny2 C.

6.2 Влияние схемы группировки

Вариант A (56 разреженных таргетов) работает на уровне базовой линии предсказания среднего (корреляция Спирмена = 0,047). При 654 обучающих примерах недостаточно данных для обучения индивидуальным распределениям эмодзи. Вариант C (3 группы) стабильно превосходит вариант B (5 групп) по всем моделям, подтверждая, что более грубая группировка лучше подходит для имеющегося объёма данных.

6.3 TF-IDF против трансформера

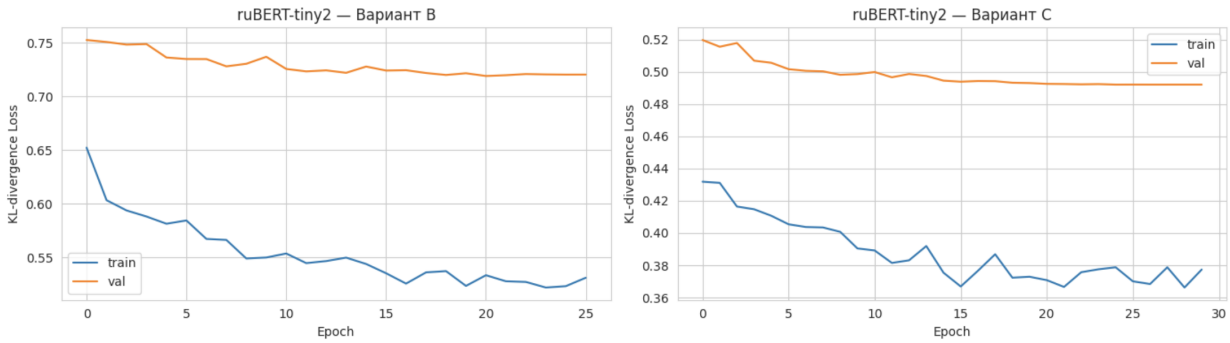

Figure 2: Рис. 2: Кривые обучения трансформера

TF-IDF + Ridge превосходит ruBERT-tiny2 по всем вариантам, несмотря на превосходящую репрезентационную ёмкость трансформера. Это ожидаемо: при 523 обучающих примерах и модели с 29 млн параметров трансформер склонен к переобучению. Кривые обучения подтверждают, что потери на валидации стабилизируются рано, тогда как тренировочные продолжают снижаться. Режим замороженного backbone (использование BERT как фиксированного экстрактора признаков) оказался более стабильным, особенно для варианта C.

6.4 Анализ по отдельным scores

Модель	negative	neutral	positive	среднее
Ridge (C)	0,391	0,174	0,503	0,356
Gradient Boosting (C)	0,358	0,143	0,430	0,310
ruBERT-tiny2 (C)	0,312	0,098	0,319	0,243

Table 4: Корреляция Спирмена по отдельным scores, вариант C.

Score *positive* предсказывается лучше всего (корреляция Спирмена = 0,503 для Ridge), затем *negative* (0,391). Score *neutral* сложнее всего поддаётся предсказанию (0,174): вероятно, потому, что *shock* и *laugh* имеют разные причины, но объединены в одну группу.

6.5 Интерпретируемость: SHAP-анализ

Значения SHAP для Ridge-модели выявляют следующие лексические триггеры:

- **negative** ↑: `channel_ods`, `channel_ds_jobs`, *ml*, *участие*, *разработки*
- **positive** ↑: `channel_not_boring`, *llm*, *000* (зарплата, напр. «300 000 руб»), *engineer*, *ai*
- **neutral** ↑: *навыки*, *архитектуры*, *мониторинг*, *ml*

Идентификатор канала — доминирующий признак: состав аудитории сильно определяет стиль реакций. Среди лексических признаков наиболее значимы токены, связанные с зарплатой («000»), технологические ключевые слова («llm», «ai»), и формулировки требований («участие» — вероятно, неоплачиваемое участие в хакатонах как требование).

Визуализация весов внимания трансформера показывает, что на постах с доминирующим *negative* модель фокусируется на цифрах зарплаты, уровне позиции («Middle», «Senior») и токенах формата/локации.

6.6 Примеры предсказаний

Фрагмент вакансии	**neg**	**neu**	**pos**
«Senior ML Engineer, зарплата 350 000 руб, удалённо, международная продуктовая компания»	0,11	0,12	0,77
«ML-инженер, участие в хакатонах обязательно, зарплата не указана, офис»	0,71	0,18	0,11
«Аналитик данных, стек: Python, SQL, Tableau, опыт от 1 года»	0,25	0,52	0,23

Table 5: Примеры предсказаний модели (TF-IDF + Ridge, вариант C).

7 Заключение

Представлен пайплайн предсказания распределения эмодзи-реакций на IT-вакансии в Telegram. Собран оригинальный датасет из 654 постов из трёх русскоязычных каналов, определены три схемы группировки реакций, обучены модели TF-IDF + Ridge, Gradient Boosting и ruBERT-tiny2.

Ключевые выводы:

1. **Схема группировки имеет значение**: более грубая группировка (3 класса) превосходит более детальную при данном объёме данных
2. **TF-IDF + Ridge — сильная базовая линия**: превосходит трансформер при 654 примерах благодаря лучшим регуляризационным свойствам
3. **Идентификатор канала доминирует**: состав аудитории — сильнейший предиктор, превосходящий лексическое содержание текста
4. **Ключевые триггеры интерпретируемы**: токены зарплаты, технологические ключевые слова (LLM, AI) и формулировки требований предсказывают реакции в содержательном направлении

Для дальнейшей работы рекомендуется: (1) расширить датасет до 1 000+ примеров для полноценного дообучения трансформера; (2) добавить временные признаки для учёта дрейфа рыночных трендов; (3) извлечь структурированные признаки (диапазон зарплаты, формат работы, уровень позиции) как дополнительные входы; (4) опробовать rubert-base для лучшего покрытия длинного контекста.

References